

Classificação Few-Shot de Doenças em Plantas

Fusão de Características Global–Local com Self-Attention

O problema

Deep learning tradicional precisa de milhares de imagens rotuladas por classe. Em agricultura, isso raramente existe.

Dados escassos

Catalogar folhas doentes em campo é caro, lento e exige especialista.

Grão fino

Doenças diferem por detalhes sutis: textura, mancha, coloração local.

Fundo confunde

Extração puramente global mistura a lesão com o fundo e a folha sadia.

Solução: Few-Shot Learning — aprender novas classes com pouquíssimos exemplos.

Few-Shot Learning: o cenário 5-way 5-shot

Aprendizado

O modelo não decora uma lista fixa de classes. Ele constrói um espaço onde imagens parecidas ficam próximas e imagens diferentes ficam distantes. Cada tarefa é um episódio, com dois conjuntos:

Support Set — 5 imagens por classe. Definem os protótipos.

Query Set — 100 imagens por classe. Avaliam a generalização.

Setup

5

classes de doenças (5-way)

5

imagens de suporte por classe

25

total no Support Set

500

imagens de teste (Query)

Cinco classes, sintomas próximos



Potato Early Blight



Potato Late Blight



Tomato Bacterial Spot



Tomato Late Blight



Tomato Healthy

Support Set — 25 imagens


5 por classe. Sorteio com seed fixa (42) para reprodutibilidade.

Query Set — 500 imagens

100 por classe, totalmente disjuntas do suporte.

Batata e tomate compartilham a mesma doença (Late Blight) — o desafio é justamente separar classes visualmente próximas.

A arquitetura em uma imagem



Backbone congelado

ResNet-18 (ImageNet). Só extrai vetores — nenhum peso é atualizado.

Fusion module

Self-attention pondera os recortes locais mais informativos.

Prototype representation

Global + local normalizados (L2) e concatenados: 1024-D.

Dois ramos de extração

Ramo Global

A folha inteira (224×224) entra na ResNet-18.

- Formato e contorno da folha
- Nervuras e estrutura morfológica
- Distribuição espacial do sintoma
- Saída: vetor R_g de 512 dimensões

Ramo Local

4 recortes aleatórios (84×84, escala 0.5–1.0).

- Manchas, necroses e lesões
- Textura e microvariação de cor
- Mesma ResNet congelada, pesos partilhados
- Saída: 4 vetores R_l de 512-D cada

Por que os dois? O global sozinho dilui a lesão no contexto da folha. O local sozinho perde a noção do todo. Juntos, se complementam.

Self-Attention: qual recorte importa?

Nem todo recorte cai sobre o sintoma. Alguns pegam fundo, sombra ou tecido sadio. O módulo de atenção aprende a pesar cada um.

Recorte 1

fundo cinza

peso **BAIXO**

Recorte 2

lesão necrótica

peso **ALTO**

Recorte 3

borda da mancha

peso **ALTO**

tecido sadio
Recorte 4


peso **BAIXO**

Multi-Head Self-Attention

Cada recorte compara-se com todos os outros (Q, K, V). Recortes que “concordam” entre si, os que contêm o objeto real, reforçam-se mutuamente; os de fundo, isolados, são atenuados. A saída é a média ponderada: R_w .

Detalhe de implementação: as projeções Q/K/V são inicializadas como identidade, a atenção parte de um estado neutro, sem viés aprendido.

Cinco passos para diagnosticar



Observação: não há treino. Nenhum peso da ResNet é atualizado, nenhuma camada de classificação é ajustada. Toda a “aprendizagem” é a média de 5 vetores por classe — por isso o método não sofre overfitting com dados escassos e roda em segundos.

Implementação

```
# 1 - Backbone congelado
resnet = models.resnet18(weights=DEFAULT)
for p in self.backbone.parameters():
    p.requires_grad = False

# 2 - Global + 4 recortes locais
R_g = normalize(backbone(x))          # 512-D
R_l = [normalize(backbone(crop(x)))
        for _ in range(4)]           # 4x512-D

# 3 - Atencao sobre os locais
attn, _ = self_attention(R_l, R_l, R_l)
R_w = normalize(attn.mean(dim=1))

# 4 - Fusao global-local
feat = normalize(cat((R_g, R_w)))      # 1024-D

# 5 - Prototipo e decisao
proto[c] = support_feat[labels==c].mean(0)
pred = argmin(torch.dist(query_feat, proto))
```

Escolhas

requires_grad = False

Congela 11M de parâmetros. Zero risco de overfitting.

RandomResizedCrop

Recortes variam a cada passada — aumento implícito.

normalize(p=2)

Vetores na esfera unitária: a distância vira comparação de direção.

torch.dist(p=2)

Distância Euclidiana. Sem camada densa, sem softmax, sem treino.

Desempenho por classe

86%

acurácia global

429


acertos em 500

25

imagens de referência

Classe	Precisão	Revocação	F1-score
Potato Early Blight	0.96	0.89	0.92
Potato Late Blight	0.73	0.93	0.82
Tomato Bacterial Spot	0.89	0.80	0.84
Tomato Late Blight	0.79	0.77	0.78
Tomato Healthy	0.99	0.90	0.94

Onde estão os erros



Acertos

- 97 / 100 Potato Early Blight
- 91 / 100 Potato Late Blight
- 83 / 100 Tomato Bacterial Spot
- 46 / 100 Tomato Late Blight
- 97 / 100 Tomato Healthy

Vazamento: das 100 folhas de Tomato Late Blight, 29 foram lidas como Bacterial Spot e 23 como Potato Late Blight.

Por que Tomato Late Blight falha?

1

Sintoma disperso

A requeima cobre áreas grandes e irregulares. Recortes de 84×84 caem sobre partes muito diferentes da mesma lesão — os 5 vetores de suporte ficam dispersos e o protótipo perde nitidez.

2

Vizinhança visual


Bacterial Spot e Late Blight da batata produzem manchas escuras semelhantes. Com só 5 exemplos, os protótipos ficam próximos e a fronteira euclidiana é frágil.

3

Precisão alta, revocação baixa

0.88 de precisão significa que quando o modelo diz “Late Blight”, quase sempre acerta. Ele é conservador — deixa de reconhecer 54 das 100. O protótipo é estreito demais, não errado.

O modelo em folhas reais



Verde = acerto · Vermelho = erro

O que os exemplos mostram

1 Acertos nítidos

Folhas saudáveis e Early Blight, com sintoma bem localizado, são classificadas com folga.

2 Erros plausíveis

Quando erra, o modelo escolhe uma doença de aparência próxima — não um palpite aleatório.

3 Importância do fundo

Imagens com fundo escuro ou sombra pesada concentram erros: os recortes capturam ruído.

Conclusões

1 Poucos exemplos bastam

5 imagens por classe diagnosticaram 500 folhas com 83% de acerto.

2 A fusão global-local funciona

Contexto da folha + detalhe da lesão elevam o poder discriminativo.

3 Sem treino, sem overfitting

Backbone congelado e distância euclidiana: leve, rápido, robusto para o campo.

4 O limite está no recorte

Recortes aleatórios enfraquecem classes de sintoma disperso — é aí que evoluímos.

Obrigado!