
UNIVERSIDADE FEDERAL DE OURO PRETO
DEPARTAMENTO DE CIÊNCIA DE COMPUTAÇÃO
PROCESSAMENTO DIGITAL DE IMAGENS

Projeto de Pesquisa

CLASSIFICAÇÃO FEW-SHOT DE DOENÇAS EM
PLANTAS BASEADA NA FUSÃO DE
CARACTERÍSTICAS GLOBAL-LOCAL

Alunos: Ana Clara Pereira Esperança, Ana Paula dos Santos Tadin,
Guilherme Jesus Rios Silveira, Michelle de Oliveira Pinheiro, Otávio
Alves Gomes.

Resumo

O Few-Shot Learning (FSL) é uma abordagem de aprendizado de máquina que busca classificar novos dados utilizando apenas poucas amostras de treinamento. Essa estratégia é especialmente relevante em aplicações nas quais a obtenção de dados rotulados é limitada, como diagnóstico médico por imagem, sensoriamento remoto e classificação de espécies raras. Este projeto apresenta uma revisão do estado da arte em classificação de imagens baseada em Few-Shot Learning, abordando técnicas de meta-aprendizado, aprendizado por transferência, Vision Transformers e mecanismos de atenção. Como proposta metodológica, é estudada uma arquitetura baseada na fusão de características globais e locais, capaz de combinar informações semânticas gerais da imagem com detalhes discriminativos extraídos de regiões específicas. Os estudos analisados indicam que essa estratégia melhora a representação das classes e aumenta a capacidade de generalização dos modelos, mesmo em cenários com extrema escassez de dados.

1 Introdução

Nos últimos anos, os modelos baseados em aprendizado profundo (*deep learning*) alcançaram um sucesso notável em tarefas complexas de visão computacional em larga escala. Apesar desses avanços, a maioria dos modelos supervisionados depende de grandes volumes de dados rotulados para aprender representações robustas e generalizáveis. Essa exigência limita sua aplicação em problemas reais nos quais a coleta, a curadoria e a anotação de dados são caras, demoradas ou simplesmente inviáveis.

Nesse contexto, o Few-Shot Learning (FSL) destaca-se como um paradigma voltado ao aprendizado de novas classes a partir de poucas amostras rotuladas. Em vez de depender de centenas ou milhares de exemplos por categoria, o FSL busca construir modelos capazes de generalizar com um conjunto extremamente reduzido de instâncias de treinamento. Essa abordagem é particularmente relevante em cenários nos quais os dados são naturalmente escassos ou sensíveis, como imagens clínicas específicas, bases sujeitas a restrições de privacidade, espécies raras, eventos pouco frequentes, amostras científicas de difícil obtenção e aplicações com alto custo de anotação especializada.

Embora o FSL reduza a dependência de grandes bases rotuladas, o problema continua desafiador. Com poucas amostras disponíveis, o modelo tende a construir representações menos estáveis e menos discriminativas, o que compromete a separação entre classes visualmente semelhantes. Esse desafio torna-se ainda mais crítico em tarefas de classificação de grão fino, nas quais diferenças sutis de textura, forma, coloração ou padrão local podem ser decisivas para a decisão final.

Uma linha promissora para enfrentar essa limitação consiste em combinar informações globais e locais da imagem. De modo geral, características globais descrevem a estrutura e o contexto da cena como um todo, enquanto características locais capturam detalhes específicos de regiões menores, frequentemente mais úteis para distinguir classes semelhantes. Essa estratégia aproxima o modelo de um processo de análise mais completo, no qual contexto geral e evidências discriminativas são explorados de maneira complementar.

Com base nessa perspectiva, este trabalho investiga uma arquitetura de classificação Few-Shot baseada na fusão de características global-local, inspirada no método de Zhang et al. (2025). A abordagem combina um backbone pré-treinado para extração de características, um ramo local com

análise de recortes da imagem e um mecanismo de autoatenção (*self-attention mechanism*) para destacar regiões mais informativas. A decisão final é realizada por meio de protótipos de classe construídos a partir de representações globais e locais concatenadas e do conjunto de suporte.

Dessa forma, a principal contribuição deste trabalho é direcionada ao diagnóstico de doenças em plantas, um domínio em que a disponibilidade de imagens rotuladas também pode ser limitada e em que detalhes visuais locais possuem papel importante na diferenciação entre classes. Assim, o objetivo consiste em implementar e avaliar essa estratégia de fusão global-local em um cenário few-shot, articulando revisão bibliográfica, definição metodológica e análise experimental sobre imagens do banco PlantVillage, organizadas em um método 5-way 5-shot.

2 Revisão Bibliográfica

A classificação de imagens com poucos exemplos (Few-Shot Learning - FSL) tem recebido atenção significativa por sua capacidade de generalizar o aprendizado para novas categorias usando conjuntos de dados extremamente restritos. A seguir, são revisados cinco trabalhos recentes que fundamentam as decisões metodológicas e arquiteturais propostas neste projeto de pesquisa.

2.1 Few-Shot Fine-Grained Image Classification: A Comprehensive Review

Nesta revisão abrangente, Ren et al. (2024) exploram o problema da Classificação de Imagens de Grão Fino com Poucos Exemplos (FSFGIC). O desafio central nesse tipo de tarefa é que as diferentes categorias (como subespécies de pássaros, modelos de aviões ou doenças em folhas) apresentam variações visuais muito pequenas entre si (baixa variância inter-classe) e, ao mesmo tempo, grandes diferenças visuais dentro da mesma categoria devido a ângulos, iluminação ou ruídos de fundo (alta variância intra-classe). O estudo categoriza os métodos atuais em representações baseadas em características globais, locais e em alinhamento semântico, demonstrando que o uso isolado de vetores globais ou locais frequentemente leva à perda de capacidade discriminativa em cenários de dados escassos.

As conclusões deste artigo ajudaram a moldar o direcionamento do nosso trabalho ao evidenciar que tratar imagens agrícolas patológicas requer uma abordagem de grão fino. Isso justificou a nossa escolha por não depender exclusivamente de uma extração global da imagem, o que poderia

confundir as predições caso os padrões da doença se sobrepusessem com o fundo da imagem ou com a cor natural da folha.

2.2 Few-Shot Image Classification Algorithm Based on Global-Local Feature Fusion

O trabalho de Zhang et al. (2025) introduz uma arquitetura projetada para lidar com a escassez extrema de dados combinando características globais e locais da imagem. Em vez de treinar a rede inteira do zero, o método propõe o uso de uma espinha dorsal (*backbone*) pré-treinada e congelada. Essa rede atua de duas formas: extrai um vetor holístico da imagem inteira e extrai vetores de múltiplos recortes aleatórios (*patches*) da mesma imagem. Para fundir os recortes locais, utiliza-se um mecanismo de autoatenção (*self-attention*). Essa camada compara os diferentes recortes e atribui pesos maiores àqueles que contêm informações cruciais do objeto central, silenciando ativamente os fundos irrelevantes. O vetor local ponderado é então concatenado com o vetor global para construir protótipos de classes robustos.

Este artigo é a espinha dorsal teórica da metodologia implementada neste projeto. Toda a estratégia de utilizar a ResNet-18 como extratora congelada, a geração de recortes locais por meio de transformações, o cálculo de autoatenção sobre esses recortes para isolar as características patológicas da folha e a construção do protótipo final pela concatenação global-local foram diretamente fundamentados nos resultados otimizados e empiricamente comprovados por esta pesquisa.

2.3 Advances in Few-Shot Learning for Image Classification and Tabular Data

Em sua tese, Shysheya (2025) investiga metodologias de alta eficiência paramétrica para o aprendizado de transferência e meta-aprendizado. O trabalho demonstra que, em ambientes onde os dados são altamente limitados, atualizar uma grande quantidade de pesos da rede neural leva rapidamente ao sobreajuste (*overfitting*) e à perda da generalização. Para mitigar esse problema, o autor explora métodos de adaptação nos quais a grande maioria dos parâmetros do modelo (o *backbone*) permanece congelada, e o aprendizado se dá atualizando uma fração ínfima da rede ou utilizando abordagens não paramétricas, como a classificação por métricas de distância baseadas

no conjunto de suporte.

A fundamentação trazida por essa pesquisa validou estruturalmente a nossa abordagem de não realizar *fine-tuning* da arquitetura ResNet. Congelar a rede de extração e transferir a responsabilidade da classificação estritamente para o cálculo da Distância Euclidiana entre as imagens de consulta (*query*) e as médias vetoriais das imagens de suporte inibiu o sobreajuste aos dados escassos, mantendo o custo computacional baixo e garantindo robustez ao modelo.

2.4 Distilling Self-Supervised Vision Transformers

Este trabalho Kang et al. (2023) foca na extração e destilação de conhecimento a partir de modelos robustos de visão computacional treinados de forma autossupervisionada (sem a necessidade de rótulos humanos em massa). Os modelos de *Vision Transformers* (ViTs), quando treinados com a lógica de autossupervisão, aprendem representações incrivelmente ricas da estrutura global e local de uma imagem. A destilação permite que essas representações altamente informativas sejam transferidas para redes menores ou aplicadas diretamente como extratores universais para tarefas secundárias (*downstream tasks*) com um número mínimo de exemplos rotulados.

A teoria de que representações latentes ricas, formadas durante o pré-treinamento, são suficientes para descrever imagens complexas sem a necessidade de re-treinamento guia a premissa de uso de extratores em nosso projeto. O entendimento de que não é preciso reaprender atributos visuais básicos (como bordas e texturas) permitiu que nosso método assumisse as saídas latentes do backbone como descritores visuais já maduros e concentrasse a complexidade algorítmica apenas na junção e na atenção dessas representações.

2.5 Few-shot and meta-learning methods for image understanding

A literatura geral focada em métodos de meta-aprendizado aborda a mudança de paradigma do aprendizado tradicional. Nesse trabalho He et al. (2023), discute-se o conceito de "aprender a aprender", onde o algoritmo não é treinado para reconhecer uma lista fixa de classes, mas sim para otimizar um espaço de incorporação (*embedding*) que diferencie qualquer imagem genérica. O paradigma estrutura-se fundamentalmente em episódios, dividindo os dados em conjuntos de suporte (que introduzem as classes) e conjuntos de consulta (que avaliam o aprendizado dessas

classes de forma dinâmica).

Essa revisão consolidou o modelo de experimentação que desenvolvemos na prática. O conceito do meta-teste com episódios N -way K -shot fundamentou nosso desenho experimental de avaliar a classificação em 5 espécies/doenças de plantas (5-way), baseando-se em apenas 5 amostras visuais prévias por categoria (5-shot) no banco PlantVillage. A organização dos dados em pastas de suporte e consulta apresentada nos experimentos do nosso projeto reflete as conclusões abordadas por esse viés do meta-aprendizado.

2.6 A survey of few-shot learning in smart agriculture: developments, applications, and challenges

Neste artigo de revisão, Yang et al. (2022) mapeiam a ascensão e a aplicação das técnicas de *Few-Shot Learning* no domínio da agricultura inteligente. Os autores detalham como o alto custo e a dificuldade logística de catalogar imagens em campo tornam modelos supervisionados ineficientes. Eles identificam quatro abordagens dominantes (aumento de dados, aprendizado métrico, memória externa e otimização de parâmetros) e concluem que métodos baseados em aprendizado métrico — onde o sistema aprende a comparar a "distância" visual entre amostras — são os mais promissores para o diagnóstico de plantas no ambiente natural.

Essa pesquisa reforçou nossa escolha pelo aprendizado métrico ao invés de redes baseadas em memória ou otimização iterativa. Baseando-nos nessa revisão, decidimos estruturar a predição através do cálculo da Distância Euclidiana contra a média do conjunto de suporte, método classificado pelos autores como ideal para manter a leveza computacional necessária em aplicações agrícolas reais.

2.7 Multi-Domain Few-Shot Learning and Dataset for Agricultural Applications

O trabalho de Nuthalapati & Tunga (2021) propõe um método de *Few-Shot Learning* voltado para a classificação automática de pragas, plantas saudáveis e plantas doentes em aplicações agrícolas. A abordagem utiliza um extrator de características para gerar representações vetoriais das imagens e, em seguida, atualiza essas representações com o auxílio de Transformers, permitindo capturar

relações mais ricas entre as amostras. Para a etapa de comparação, os autores empregam a distância de Mahalanobis, que leva em conta a estrutura estatística das características extraídas e melhora a discriminação entre classes visualmente semelhantes. Além disso, o trabalho apresenta um novo conjunto de dados com imagens de plantas e doenças em condições reais de campo, o que amplia sua relevância prática.

Esse artigo é particularmente pertinente para este projeto porque mostra que o aprendizado com poucos exemplos pode ser aplicado de forma eficaz em cenários agrícolas reais, nos quais a obtenção de dados rotulados é difícil e dispendiosa. A estratégia de combinar representações aprendidas com uma métrica de distância reforça a escolha de uma arquitetura baseada em protótipos e na fusão de características, especialmente em tarefas de diagnóstico foliar em que pequenas variações visuais têm grande impacto na classificação Nuthalapati & Tunga (2021).

2.8 Distilling Self-Supervised Vision Transformers

O trabalho de Caron et al. (2021) investiga como modelos baseados em *Vision Transformers* podem aprender representações visuais robustas por meio de treinamento autossupervisionado e posterior destilação do conhecimento aprendido. A proposta parte da ideia de que, mesmo sem rótulos humanos em grande escala, a rede consegue construir descritores visuais ricos e generalizáveis ao explorar relações globais e locais dentro da imagem. A destilação permite transferir essas representações para modelos menores ou para tarefas específicas com poucos dados rotulados, mantendo boa capacidade de discriminação.

Esse artigo é relevante para o projeto porque reforça a importância de utilizar um *backbone* pré-treinado como extrator de características. A ideia de reaproveitar representações visuais já maduras, em vez de treinar toda a rede do zero, sustenta a escolha por uma arquitetura congelada e ajuda a concentrar o aprendizado na fusão das características e na comparação entre protótipos.

3 Metodologia

3.1 Fundamentação do Método

O método empregado neste trabalho baseia-se na abordagem de Aprendizado por Poucos Exemplos (*Few-Shot Learning* – FSL), modelada como um problema de classificação do tipo *N-way K-shot*. A estratégia fundamenta-se no paradigma de Redes Prototípicas (*Prototypical Networks*), no qual cada classe é representada pelo vetor médio das características extraídas de suas imagens de suporte. Dessa forma, a classificação de uma nova imagem ocorre por meio do cálculo da distância entre sua representação vetorial e os protótipos previamente construídos, dispensando o retreinamento completo da rede.

Para aumentar a capacidade discriminativa em cenários agrícolas, nos quais os sintomas costumam aparecer em pequenas regiões das folhas, adota-se uma arquitetura baseada na Fusão de Características Global-Local com mecanismo de Autoatenção (*Self-Attention*). O ramo global captura informações estruturais da folha, enquanto os recortes locais concentram-se em pequenas regiões contendo manchas ou necroses. O mecanismo de atenção permite que o modelo atribua maior importância às regiões locais visualmente relevantes, silenciando ruídos de fundo.




Figura 1: Modelo de fusão global/local

3.2 Base de Dados

Os experimentos foram realizados utilizando o banco de dados PlantVillage, amplamente utilizado em pesquisas de classificação de doenças em plantas. Para modelar um diagnóstico de doenças foliares, foram selecionadas cinco categorias:

- Potato Early Blight (Pinta-preta da batata);
- Potato Late Blight (Requeima da batata);
- Tomato Bacterial Spot (Mancha bacteriana do tomate);
- Tomato Late Blight (Requeima do tomate);
- Tomato Healthy (Folha de tomate saudável).



Figura 2: Exemplos das cinco classes utilizadas no experimento: Potato Early Blight, Potato Late Blight, Tomato Bacterial Spot, Tomato Late Blight e Tomato Healthy.

O problema foi configurado no paradigma *5-way 5-shot*. Foram selecionadas cinco imagens por classe para compor o conjunto de suporte (*Support Set*), responsáveis por gerar os protótipos, e cem imagens independentes por classe para o conjunto de consulta (*Query Set*). O conjunto experimental totalizou 25 imagens de suporte e 500 imagens de consulta.

3.3 Arquitetura do Modelo

A arquitetura implementada baseia-se no método de Classificação Few-Shot via Fusão de Características Global-Local, utilizando como extrator de características (*backbone*) uma rede ResNet-18 previamente treinada na base ImageNet. Diferentemente dos classificadores tradicionais baseados em aprendizado profundo, não é realizado o processo de ajuste fino (*fine-tuning*)

da rede. Durante todo o experimento, os pesos da ResNet-18 permanecem congelados, sendo utilizados apenas para extrair representações discriminativas das imagens.

Essa estratégia reduz significativamente o custo computacional e elimina a necessidade de grandes quantidades de imagens rotuladas para treinamento. Em vez de aprender novamente os parâmetros da rede para cada nova doença, o modelo utiliza o conhecimento previamente adquirido pela ResNet-18 para representar cada folha em um espaço de características. A extração das informações ocorre por meio de dois ramos complementares.

- **Ramo Global:** processa a imagem completa da folha, capturando informações relacionadas ao formato geral, contorno, nervuras e demais características morfológicas da planta.
- **Ramo Local:** divide a imagem em cinco regiões (quatro cantos e uma região central), permitindo analisar detalhes específicos como manchas, necroses, alterações de textura e pequenas variações de coloração provocadas pelas doenças.

As características obtidas pelos recortes locais são encaminhadas para um mecanismo de *Multi-Head Self-Attention*. Esse módulo calcula automaticamente quais regiões da folha apresentam maior relevância para o diagnóstico, atribuindo pesos maiores às áreas contendo sintomas e reduzindo a influência de regiões pouco informativas, como fundo da imagem ou partes saudáveis da folha. Após essa etapa, o vetor global e o vetor local refinado são normalizados utilizando a norma L_2 e concatenados, formando uma representação híbrida da folha. Essa representação reúne simultaneamente informações globais da planta e detalhes locais das lesões, tornando a descrição da imagem mais discriminativa.

Por fim, essa representação híbrida é utilizada pelo classificador prototípico. Em vez de treinar uma camada de classificação convencional, o modelo compara o vetor da folha com os protótipos construídos a partir das imagens de suporte, atribuindo a classe cuja distância Euclidiana seja a menor. Dessa forma, novas doenças podem ser classificadas utilizando apenas poucas imagens de referência, sem necessidade de retreinamento da rede.

A Figura 3 apresenta o fluxo completo da arquitetura utilizada.




Figura 3: Arquitetura do modelo Few-Shot baseado na fusão global-local com mecanismo de autoatenção.

3.4 Pipeline de Classificação

O procedimento de predição é estruturado em duas etapas principais: a construção da representação das categorias e a classificação das novas amostras. O fluxo ocorre da seguinte forma:

Etapa 1: Construção dos Protótipos (Conjunto de Suporte)

1. **Extração de características:** A rede ResNet-18 processa as imagens do conjunto de suporte, gerando os vetores de características globais e os recortes locais;
2. **Fusão e Autoatenção:** O mecanismo de autoatenção avalia os vetores locais para extrair as áreas mais relevantes. Em seguida, o resultado é concatenado ao vetor global de cada imagem;
3. **Definição dos protótipos:** Calcula-se a média vetorial das cinco representações híbridas de cada categoria para formar o protótipo de classe.

Etapa 2: Classificação (Conjunto de Consulta)

4. **Processamento da consulta:** As imagens do conjunto de consulta (*Query Set*) passam exatamente pelo mesmo processo de extração e fusão descrito na etapa anterior;

5. **Cálculo de similaridade:** Mede-se a distância Euclidiana entre o vetor resultante de cada imagem de consulta e os protótipos de classe previamente calculados;
6. **Atribuição de rótulo:** A amostra é classificada com a categoria correspondente ao protótipo que apresentar a menor distância vetorial.

3.5 Métricas de Avaliação

O desempenho foi medido por acurácia, precisão, revocação, F1-score e matriz de confusão. Essas métricas avaliam a taxa global de acertos e o comportamento individual para cada classe.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (1)$$

Para complementar a avaliação do modelo, foram utilizadas as métricas de **Precisão e Revocação**. A **Precisão** indica o percentual de classificações positivas realizadas pelo modelo que estão corretas, enquanto a **Revocação** mede a capacidade do classificador em identificar corretamente todas as plantas pertencentes a uma determinada doença.

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (2)$$

$$\text{Revocação} = \frac{VP}{VP + FN} \quad (3)$$

A métrica **F1-score** resume ambas através de sua média harmônica:

$$F_1 = 2 \cdot \frac{\text{Precisão} \times \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (4)$$

Adicionalmente, a **Matriz de Confusão** foi gerada para mapear os acertos na diagonal principal e identificar sobreposições ou confusões sistemáticas entre doenças visualmente semelhantes.

4 Resultados

4.1 Contextualização do Cenário de Teste

Após a construção dos protótipos utilizando o conjunto de suporte (*Support Set*), o modelo foi avaliado em um conjunto independente de imagens (*Query Set*), permitindo analisar sua capacidade de generalização para amostras nunca vistas durante a etapa de suporte. O conjunto de consulta foi composto por 500 imagens reais de folhas. As imagens foram distribuídas igualmente entre cinco classes, totalizando 100 imagens para cada doença analisada: *Potato Early Blight*, *Potato Late Blight*, *Tomato Bacterial Spot*, *Tomato Late Blight* e *Tomato Healthy*.

Essa configuração difere do conjunto de suporte utilizado pelo modelo Few-Shot. Enquanto apenas cinco imagens de cada classe foram empregadas para construir os protótipos, todas as 500 imagens restantes foram utilizadas exclusivamente para avaliação. Dessa forma, o modelo precisou reconhecer corretamente centenas de folhas utilizando como referência apenas cinco exemplos previamente conhecidos de cada doença.

4.2 Análise Quantitativa


A Tabela 1 apresenta os resultados obtidos pelo modelo no teste de generalização. O método alcançou uma acurácia global de **86%**, realizando corretamente **429** classificações entre as **500** imagens avaliadas.

Tabela 1: Desempenho do modelo no conjunto de teste			
Classe	Precisão	Revocação	F1-score
Potato Early Blight	0.96	0.89	0.92
Potato Late Blight	0.73	0.93	0.82
Tomato Bacterial Spot	0.89	0.80	0.84
Tomato Late Blight	0.79	0.77	0.78
Tomato Healthy	0.99	0.90	0.94
Acurácia Global	86% (429 acertos / 500 imagens)		

Observa-se que as classes *Potato Early Blight* e *Tomato Healthy* apresentaram os melhores

resultados, com F1-score superior a 0,90. Em contrapartida, a classe *Tomato Late Blight* apresentou o menor desempenho entre as cinco categorias avaliadas, embora tenha obtido resultados mais equilibrados em precisão, revocação e F1-score quando comparados aos experimentos anteriores.

A Figura apresenta a matriz de confusão obtida durante o teste de generalização e alguns exemplos de imagens do conjunto de consulta com suas respectivas classificações realizadas pelo modelo.



A matriz de confusão evidencia que a maior parte das amostras foi classificada corretamente, enquanto os exemplos apresentados ilustram qualitativamente o comportamento do modelo em imagens reais do conjunto de teste.

5 Conclusão

Os resultados confirmam que a fusão de características global-local, aliada a um mecanismo de autoatenção, é uma estratégia eficaz para classificação Few-Shot de doenças em plantas, mesmo utilizando apenas cinco imagens de suporte por classe. A acurácia de 86% obtida no conjunto de consulta indica que a combinação de contexto morfológico global com detalhes locais de lesões contribui de fato para a discriminação entre categorias visualmente próximas.

O menor desempenho observado na classe *Tomato Late Blight* sugere que sintomas com padrões visuais mais sutis ou sobrepostos a outras doenças ainda representam um desafio para o mecanismo de atenção proposto. Como direcionamento futuro, a substituição do *backbone* por

arquiteturas baseadas em Vision Transformers autossupervisionados, bem como a incorporação de métricas de distância mais robustas, como a de Mahalanobis, podem ampliar a capacidade discriminativa do modelo em cenários agrícolas reais.

Referências

- Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision* (pp. 9650–9660).
- He, K., Pu, N., Lao, M., & Lew, M. S. (2023). Few-shot and meta-learning methods for image understanding: A survey. *International Journal of Computer Vision*.
- Kang, D., Koniusz, P., Cho, M., & Murray, N. (2023). Distilling self-supervised vision transformers for weakly-supervised few-shot classification and segmentation..
- Nuthalapati, S. V., & Tunga, A. (2021). Multi-domain few-shot learning and dataset for agricultural applications. In *Proceedings of the IEEE/CVF international conference on computer vision workshops*. doi: 10.48550/arXiv.2109.09952
- Ren, J., Li, C., An, Y., Zhang, W., & Sun, C. (2024). Few-shot fine-grained image classification: A comprehensive review. *Information Fusion*.
- Shysheya, A. (2025). Advances in few-shot learning for image classification and tabular data. *University of Cambridge*.
- Yang, J., Guo, X., Li, Y., Marinello, F., Ercisli, S., & Zhang, Z. (2022). A survey of few-shot learning in smart agriculture: developments, applications, and challenges. *Plant Methods*, 18(1), 28. doi: 10.1186/s13007-022-00866-2
- Zhang, L., Yang, X., Cheng, X., Cheng, W., & Lin, Y. (2025). Few-shot image classification algorithm based on global–local feature fusion. *AI*, 6(1), 265.